

EfficientViT: Memory Efficient Vision Transformer with Cascaded Group Attention

Xinyu Liu, Houwen Peng, Ningxin Zheng, Yuqing Yang, Han Hu, Yixuan Yuan

목차

EfficientVit

제안 방법


실험 세팅

결과 및 분석

EfficientViT

핵심목표

기존 ViT의 높은 정확도를 유지하면서,
실행 속도(Latency)와 메모리 효율성을
극대화하여 모바일 및 엣지 디바이스에
최적화



EfficientViT

아키텍처


샌드위치 레이아웃(Sandwich Layout)

FFN $\rightarrow$ MHSA $\rightarrow$ FFN 구조

메모리를 많이 사용하는 MHSA층을 최소화

연산효율이 좋은 FFN을 전후로 배치하여
정보 전달력 보완

메모리 대역폭 사용량을 줄여 전체적인
추론 속도 향상



EfficientVit

아키텍처


계단식 그룹 어텐션

(Cascaded Group Attention (CGA))

다양한 특징 학습을 위해 헤드별로 feature split을 통해 서로 다른 입력을 처리

Head 1의 출력을 Head 2의 입력에 더함

RNN과 같은 순차적인 형태를 띠




EfficientVit

아키텍처

파라미터 재할당

Q, K 차원 축소

어텐션 연산 시 다루는 행렬의 크기가 작아져서 메모리 접근 비용이 획기적으로 줄어듦.




EfficientVit

문제점

RNN과 같은 순차적인 형태
(직렬적인 연결)

gpu의 강점인 병렬처리가 불가능해짐
($H1 \rightarrow H2 \rightarrow H3$)

이에 따라 추론 속도가 늦어질 수 있음



제안 방법

1. Stage2의 Self Attention을 병렬처리


V1 : $(H1 \rightarrow H2) \parallel (H3)$

V2 : $(H1 \parallel H2) \rightarrow (H3)$


2. 속도 향상을 위한 Flash Attention 도입

메모리 대역폭 사용량을 최소화하여 속도와 메모리 효율을 올릴 수 있음

V1



V2



제안 방법

Stage

Stage 1



Feature Map이 커 처리 할 데이터 양 많음, 채널 수 적음

Stage 2

Feature Map의 크기와 채널 깊이가 병렬 처리를 적용했을 때 GPU 활용도를 높이기 위해 가장 적절한 균형을 이루고 있다고 판단.

Stage 3

Feature Map이 작음
일 나누는 시간(오버헤드)이 실제 계산 시간보다 더 길어짐.



제안 방법

Flash Attention


기존 Attention

행렬 데이터를 HBM에서 꺼내서 SRAM으로 꺼내고
넣었다가 꺼내는 것을 반복
메모리 접근이 연산보다 오래걸리는 현상이 발생함
(IO Bottleneck)

Flash Attention

쪼개서 계산(Tiling)하여 SRAM 안에서 처리를 끝내고,
중간 결과를 저장 안 하고 다시 계산(Recomputation)
하는 방식

메모리 대역폭 사용량을 최소화하여 속도와 메모리 효율
을 올릴 수 있음




실험 세팅

	ImageNet	Cifar-10
Img_size	224	32
patch_size	16	2
embed_dim	[128,192,224]	[128,192,224]
depth	[1,2,3]	[1,2,3]
num_heads	[4,3,2]	[4,3,2]
window_size	[7,7,7]	[4,4,4]
kernels	[7,5,3,3]	[7,5,3,3]


제안 방법 비교

Base, V1, V2




학습시간

Base, V1, V2, FlashAttn




추론시간

Base, V1



Flash Attention 적용


Base, V1, FlashAttn



학습 시간


Base, V1, FlashAttn

Training Time Comparison



추론 시간

Base, V1, FlashAttn



결과 분석 및 결론

V1 (Stage 2 병렬화) 적용 결과: 학습 시간은 2분 소폭 증가했지만, 추론 단계에서 시간 감소를 달성함

V1 + FlashAttn 적용 결과: 학습 시간은 크게 증가했으나, 추론 단계에서는 훨씬 더 큰 폭의 시간 감소를 달성하였음.

Stage 2 병렬화(V1) + Flash Attention은 EfficientViT의 구조적 비효율성을 효과적으로 개선함과 동시에 기존의 성능을 유지할 수 있는 유효한 경량화 전략임을 알 수 있었음.